



ΕΘΝΙΚΟ ΜΕΤΣΟΒΙΟ ΠΟΛΥΤΕΧΝΕΙΟ
ΣΧΟΛΗ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ ΚΑΙ ΜΗΧΑΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ
ΤΟΜΕΑΣ ΣΥΣΤΗΜΑΤΩΝ ΜΕΤΑΔΟΣΗΣ ΠΛΗΡΟΦΟΡΙΑΣ ΚΑΙ ΤΕΧΝΟΛΟΓΙΑΣ ΥΛΙΚΩΝ

«Αναγνώριση Χειρονομιών από Επιφανειακό Ηλεκτρομυογράφημα (sEMG) για τον έλεγχο Νευροπροσθετικών Συσκευών Άνω Άκρων με χρήση Φασματογραφημάτων και Συνελκτικών Νευρωνικών Δικτύων»

Εξαμηνιαία Εργασία

στο μάθημα «Τεχνολογίες Ψηφιακής Υγείας»

**Βασιλαράς Δημήτριος , ΑΜ:03122184
Καλιάτσης Βασιλείος , Α.Μ.: 03122148
Κουλατζίδης Παύλος , ΑΜ:03122185
Μπάλλος Γεώργιος , ΑΜ:03122076**

Διδάσκοντες: Δ. Κουτσούρης, Κ. Νικήτα, Γ. Ματσόπουλος, Π. Τσανάκας, Ι. Δελής, Ρ. Πετροπούλου

Επιβλέπων: Ματσόπουλος Γεώργιος

Αθήνα, Μάιος 2026

Περίληψη

Οι ακρωτηριασμοί των άνω άκρων επηρεάζουν εκατομμύρια ανθρώπους παγκοσμίως, περιορίζοντας την αυτονομία και την ποιότητα ζωής τους. Παρά την τεχνολογική πρόοδο, ο έλεγχος των νευροπροσθετικών συσκευών παραμένει δύσκολος λόγω της μη φυσικής διεπαφής και της υψηλής μεταβλητότητας των σημάτων επιφανειακού ηλεκτρομυογραφήματος (sEMG). Η παρούσα εργασία στοχεύει στην ανάπτυξη ενός συστήματος αναγνώρισης χειρονομιών χεριού σε πραγματικό χρόνο, αξιοποιώντας τεχνικές βαθιάς μάθησης.

Αξιολογήθηκαν συγκριτικά τέσσερις νευρωνικές αρχιτεκτονικές: SlowFusion 3D-CNN, MobileNetV2 με μεταφορά μάθησης, και δύο παραλλαγές Temporal Convolutional Networks (TCN-AoT, TCN-Att). Τα σήματα sEMG από οκτώ κανάλια του Myo Armband προεπεξεργάστηκαν με φιλτράρισμα 50 Hz, τμηματοποίηση σε παράθυρα 260 ms, και μετατράπηκαν σε φασματογραφήματα STFT για τις CNN ή χρησιμοποιήθηκαν ακατέργαστα για τα TCN. Η αξιολόγηση πραγματοποιήθηκε στο NinaPro DB5 (17 κλάσεις, 5 χρήστες).

Το TCN-AoT επέτυχε τη μέγιστη μέση ακρίβεια (63.2%) με ελάχιστο υπολογιστικό αποτύπωμα (24k παράμετροι, 0.1 MB) και p95 latency 3.05 ms, καθιστώντας το την καταλληλότερη επιλογή για ενσωματωμένα συστήματα πραγματικού χρόνου. Όλες οι αρχιτεκτονικές ικανοποίησαν το κλινικό όριο των 300 ms. Τα αποτελέσματα αναδεικνύουν τη βιωσιμότητα των ελαφριών TCN για νευροπροσθετικές εφαρμογές.

Λέξεις Κλειδιά

Επιφανειακό Ηλεκτρομυογράφημα (sEMG), Αναγνώριση Χειρονομιών, Temporal Convolutional Networks, Νευροπροσθετικές Συσκευές, Πραγματικός Χρόνος

Πίνακας περιεχομένων

1	Εισαγωγή.....	6
1.1.	Ηλεκτρομυογραφία (EMG): Φυσιολογία, Σήμα και Προκλήσεις	6
1.1.1	Φυσιολογία του Μυός και Παραγωγή του Σήματος.....	6
1.1.2	Μαθηματικό Μοντέλο του MUAP	7
1.1.3	Φυσικά και Στατιστικά Χαρακτηριστικά του EMG	8
1.1.4	Φυσιολογικοί και Περιβαλλοντικοί Παράγοντες που Επηρεάζουν το EMG.....	8
1.1.5	Μέθοδοι Καταγραφής EMG	9
1.2	Επιφανειακή Ηλεκτρομυογραφία (sEMG): Χαρακτηριστικά, Θόρυβος και Ερευνητικές Προκλήσεις	9
1.2.1	Μορφές Συστημάτων sEMG.....	10
1.2.2	Πηγές Θορύβου στο sEMG	10
1.2.3	Παράγοντες Μεταβλητότητας του sEMG	11
1.2.4	Επιπτώσεις της Μεταβλητότητας στη Χρήση του sEMG	13
1.2.5	Σημασία του sEMG και Πεδία Εφαρμογής	14
1.2.6	Συνολική Ερευνητική Πρόκληση	14
1.3	Η Συμβολή της Βαθιάς Μάθησης (Deep Learning) στην Αναγνώριση Χειρονομιών	15
1.3.1	Από την Κλασική Μηχανική Μάθηση στην Αυτόματη Εξαγωγή Χαρακτηριστικών	15
1.3.2	Χωροχρονική Ανάλυση μέσω CNNs και Ανάλυση Ακολουθιών μέσω TCN	16
1.3.3	Υπέρβαση των Περιορισμών Υλικού: Ενέργεια, Κόστος και Edge AI.....	17
1.4	Μεθοδολογική Προσέγγιση και Σημασία της Εργασίας	17
1.5	Ερευνητικά Ερωτήματα	18
2	Υλικό και Μέθοδοι	20
2.1	Περιγραφή του Συνόλου Δεδομένων (NinaPro DB5) και Διαχωρισμός (Split)	20
2.1.1	Συμμετέχοντες και Συσκευές-Εξοπλισμός Καταγραφής.....	20
2.1.2	Κινήσεις και Πειράματα κατά την καταγραφή	21

2.1.3	Μορφή των ακατέργαστων δεδομένων στο dataset.....	21
2.1.4	Διαχωρισμός δεδομένων σε training και test set	22
2.2	Προεπεξεργασία (Preprocessing) και Εξαγωγή Χαρακτηριστικών (Feature Extraction).....	22
2.3	Αρχιτεκτονική Νευρωνικών Δικτύων.....	24
2.3.1	Αρχιτεκτονική Σταδιακής Συγχώνευσης (Slow Fusion CNN)	25
2.3.2	Αρχιτεκτονική MobileNetV2 και Transfer Learning.....	25
2.3.3	Αρχιτεκτονικές Temporal Convolutional Networks.....	26
2.4	Εκπαίδευση και Κριτήρια Αξιολόγησης Μοντέλων.....	27
2.4.1	Περιβάλλον Εκπαίδευσης και Διαμόρφωση Δεδομένων.....	27
2.4.2	Συνάρτηση Κόστους και Βελτιστοποιητής.....	27
2.4.3	Στρατηγική Πρώιμης Διακοπής (Early Stopping)	28
2.4.4	Μετρικές Αξιολόγησης	28
3	Αποτελέσματα.....	30
3.1	Μετρικές Ταξινόμησης	30
3.2	Ανάλυση Πινάκων Σύγκρισης.....	32
3.3	Αξιολόγηση Καταλληλότητας Πραγματικού Χρόνου.....	33
4	Επίλογος-Συμπεράσματα	38
4.1	Σύνοψη και συμπεράσματα.....	38
4.2	Μελλοντικές επεκτάσεις	40
5	Βιβλιογραφία	43

1

Εισαγωγή

Η αναγνώριση χειρονομιών μέσω σημάτων επιφανειακού ηλεκτρομυογραφήματος (sEMG) αποτελεί μια από τις πιο υποσχόμενες προσεγγίσεις για την ανάπτυξη φυσικών και διαισθητικών Διεπαφών Ανθρώπου-Μηχανής (HMIs). Ωστόσο, η αξιόπιστη χρήση τέτοιων συστημάτων σε πραγματικές συνθήκες περιορίζεται από προκλήσεις όπως η μεταβλητότητα της στάσης του βραχίονα, η πάροδος του χρόνου (χρονική μεταβλητότητα) και οι αλλαγές στην τοποθέτηση των αισθητήρων. Η παρούσα εργασία στοχεύει στην αντιμετώπιση αυτών των προβλημάτων, διερευνώντας τη μετάβαση από την κλασική μηχανική μάθηση σε μεθόδους Βαθιάς Μάθησης (Deep Learning), με απώτερο σκοπό την ανάπτυξη έξυπνων συστημάτων ικανών να λειτουργούν σε πραγματικό χρόνο και κάτω από σημαντικούς περιορισμούς ισχύος, μεγέθους και κόστους.

1.1. Ηλεκτρομυογραφία (EMG): Φυσιολογία, Σήμα και Προκλήσεις

Η ηλεκτρομυογραφία (Electromyography, EMG) αποτελεί τον επιστημονικό κλάδο που μελετά τη βιοηλεκτρική δραστηριότητα των σκελετικών μυών. Το ηλεκτρομυογραφικό σήμα παράγεται από την ηλεκτρική διέγερση των μυϊκών ινών, η οποία οφείλεται στη ροή ιόντων Na^+ και K^+ διαμέσου της κυτταρικής μεμβράνης κατά τη σύσπαση τους. Επειδή η διέγερση αυτή προκύπτει ως αποτέλεσμα της εντολής του κεντρικού νευρικού συστήματος μέσω των κινητικών νευρώνων, το EMG αποτελεί μία από τις καλύτερες μεθόδους έμμεσης εκτίμησης της ανθρώπινης πρόθεσης κίνησης [3].

1.1.1 Φυσιολογία του Μυός και Παραγωγή του Σήματος

Κάθε σκελετικός μυς αποτελείται από πολλές κινητικές μονάδες (Motor Units – MUs), οι οποίες συνιστούν τη βασική λειτουργική μονάδα του μυϊκού συστήματος. Κάθε κινητική μονάδα περιλαμβάνει έναν κινητικό νευρώνα (α -motoneuron) και το σύνολο των μυϊκών ινών που νευρώνει. Η ενεργοποίηση μιας MU παράγει το δυναμικό δράσης

της κινητικής μονάδας (Motor Unit Action Potential – MUAP), το οποίο αποτελεί το άθροισμα των συνεισφορών όλων των μυϊκών ινών που ανήκουν σε αυτήν [1].

Η διαδοχική ενεργοποίηση μιας κινητικής μονάδας παράγει τα MUAP Trains (MUAPTs), τα οποία διαρκούν όσο ο μυς είναι σε θέση να παράγει δύναμη. Το συνολικό EMG σήμα που καταγράφεται σε δεδομένη χρονική στιγμή προκύπτει από την υπέρθεση όλων των MUAPs των ενεργών κινητικών μονάδων που βρίσκονται εντός της περιοχής ανίχνευσης [3]:

$$m(t; F) = \sum_{\text{unit} \in U} u_{\text{unit}}(t; F)$$

όπου F είναι η δύναμη που παράγει ο μυς και U το σύνολο των ενεργών κινητικών μονάδων. Η ένταση της μυϊκής δραστηριότητας ρυθμίζεται από δύο μηχανισμούς:

- Recruitment: προοδευτική ενεργοποίηση περισσότερων κινητικών μονάδων.
- Rate coding: αύξηση της συχνότητας εκφόρτισης των ενεργών μονάδων.

Η ταυτόχρονη ύπαρξη και των δύο μηχανισμών καθιστά το EMG πλούσιο σε φυσιολογική πληροφορία, αλλά παράλληλα εξαιρετικά σύνθετο ως σήμα.

1.1.2 Μαθηματικό Μοντέλο του MUAP

Στο πλαίσιο της θεωρίας γραμμικής απόκρισης, ένα MUAPT μπορεί να μοντελοποιηθεί πλήρως μέσω δύο μαθηματικών οντοτήτων [3]:

1. Της χρονικής ακολουθίας των παλμών ενεργοποίησης

$$\{t_i\}_{i=1, \dots, n}$$

2. Της κυματομορφής MUAP $h(t)$, που αντιπροσωπεύει τη συνάρτηση γραμμικής απόκρισης.

Το συνολικό σήμα ενός MUAPT εκφράζεται ως συνέλιξη:

$$u(t) = (h * \bar{\delta})(t) = \sum_{i=1}^n h(t - t_i)$$

όπου $\delta(t)$ είναι το τρένο των κρουστικών παλμών Dirac. Η κυματομορφή $h(t)$ εξαρτάται από τη γεωμετρική σχέση μεταξύ του ηλεκτροδίου και των ενεργών μυϊκών ινών, καθώς και από βιοχημικές μεταβολές, όπως αυτές που επιφέρει η μυϊκή κόπωση [3].

1.1.3 Φυσικά και Στατιστικά Χαρακτηριστικά του EMG

Το ακατέργαστο EMG σήμα παρουσιάζει συγκεκριμένα χαρακτηριστικά [1][3]:

- Πλάτος: τυπικά μεταξύ 10 μ V και 10 mV, εξαρτώμενο από το μέγεθος και την απόσταση των μυών από τα ηλεκτρόδια.
- Εύρος ζώνης: έως περίπου 500 Hz, με την κύρια ενέργεια του σήματος να συγκεντρώνεται στην περιοχή 20-450 Hz.
- Στατιστική φύση: το σήμα είναι μη στάσιμο, μη γραμμικό, στοχαστικό και απρόβλεπτο, αντανακλώντας τη συνεχή μεταβολή του συνόλου των ενεργών κινητικών μονάδων και τον τυχαίο τρόπο υπέρθεσης των MUAPs [1].
- Στιγμιαία συμπεριφορά: η τιμή του σήματος μπορεί να μεταβάλλεται γρήγορα μεταξύ θετικών και αρνητικών τιμών, προσομοιάζοντας με στοχαστική διαδικασία μηδενικού μέσου, της οποίας η τυπική απόκλιση είναι ανάλογη του αριθμού των ενεργών κινητικών μονάδων και του ρυθμού ενεργοποίησής τους [1].

Λόγω αυτής της στοχαστικής φύσης (θόρυβος, αστάθεια κ.λ.π.), η άμεση χρήση της στιγμιαίας τιμής του EMG θεωρούνταν παραδοσιακά μη αξιοποιήσιμη για ανάλυση μοτίβων, οδηγώντας τους ερευνητές σε τεχνικές windowing και εξαγωγής στατιστικών χαρακτηριστικών [1].

1.1.4 Φυσιολογικοί και Περιβαλλοντικοί Παράγοντες που Επηρεάζουν το EMG

Το EMG επηρεάζεται από πλήθος παραγόντων, οι οποίοι εισάγουν σημαντική μεταβλητότητα στη μορφή του σήματος [1][3]:

- Μυϊκή κόπωση: προκαλεί μεταβολή της κυματομορφής MUAP, με μείωση των υψηλών συχνοτήτων και αύξηση του πλάτους.
- Υποδόριο λίπος: λειτουργεί ως φίλτρο χαμηλής διέλευσης, εξασθενώντας το σήμα και αυξάνοντας το crosstalk μεταξύ γειτονικών μυών.

- Ταχύτητα και τύπος σύσπασης: επηρεάζουν τη φασματική κατανομή του σήματος.
- Θερμοκρασία δέρματος και ενυδάτωση: μεταβάλλουν την αγωγιμότητα.
- Ηλεκτρομηχανική καθυστέρηση (electromechanical delay): η χρονική απόσταση μεταξύ της ηλεκτρικής διέγερσης και της μηχανικής σύσπασης.
- Ανατομικές διαφορές μεταξύ ατόμων: μέγεθος μυός, πάχος δέρματος, κατανομή λιπώδους ιστού.

Οι παραπάνω παράγοντες θέτουν σοβαρούς περιορισμούς στη χρήση του EMG σε εφαρμογές που απαιτούν αξιοπιστία, επαναληψιμότητα και διαχρονική σταθερότητα.

1.1.5 Μέθοδοι Καταγραφής EMG

Η καταγραφή του EMG πραγματοποιείται με δύο βασικές προσεγγίσεις [1][3]:

- Επεμβατική (invasive) ηλεκτρομυογραφία: χρήση ενδομυϊκών ηλεκτροδίων τύπου σύρματος ή βελόνας. Παρέχει υψηλή ειδικότητα και ικανότητα απομόνωσης μεμονωμένων κινητικών μονάδων, αλλά είναι ενοχλητική, επώδυνη και ακατάλληλη για μακροχρόνια ή καθημερινή χρήση.
- Μη επεμβατική (Non-invasive) ηλεκτρομυογραφία (sEMG): χρήση ηλεκτροδίων στην επιφάνεια του δέρματος, χωρίς διείσδυση. Είναι η μόνη πρακτικά αξιοποιήσιμη μέθοδος για wearable συστήματα, διεπαφές ανθρώπου-μηχανής και προθετικές εφαρμογές (αποκαλείται και επιφανειακή Ηλεκτρομυογραφία).

Η επιλογή της επιφανειακής μεθόδου αποτελεί προϋπόθεση για κάθε σύγχρονη εφαρμογή πραγματικού χρόνου, και αποτελεί τη βάση της παρούσας εργασίας.

1.2 Επιφανειακή Ηλεκτρομυογραφία (sEMG): Χαρακτηριστικά,

Θόρυβος και Ερευνητικές Προκλήσεις

Η επιφανειακή ηλεκτρομυογραφία (surface EMG, sEMG) αποτελεί τη μη επεμβατική παραλλαγή της ηλεκτρομυογραφίας, στην οποία όπως αναφέρθηκε και προηγουμένως η καταγραφή της μυϊκής δραστηριότητας πραγματοποιείται μέσω ηλεκτροδίων

τοποθετημένων στην επιφάνεια του δέρματος. Το sEMG σήμα αντιπροσωπεύει την χωροχρονική κατανομή των δυναμικών δράσης που παράγονται από τις κινητικές μονάδες των μυών που βρίσκονται εντός της περιοχής ανίχνευσης του ηλεκτροδίου, και αποτελεί μια έμμεση αλλά λειτουργική απεικόνιση των υποκείμενων φυσιολογικών διεργασιών της μυϊκής δραστηριότητας [1].

Στη βασική διάταξη sEMG, τα δυναμικά δράσης ανιχνεύονται μέσω ενός ενισχυτή οργανολογίας, του οποίου οι θετικοί και αρνητικοί πόλοι συνδέονται σε δύο μεταλλικές πλάκες τοποθετημένες στην επιφάνεια του δέρματος. Το προκύπτον σήμα προέρχεται από την υπέρθεση όλων των ανιχνευόμενων MUAPs που βρίσκονται κάτω από την περιοχή του ενισχυτή [3]. Η μη επεμβατικότητα της μεθόδου την καθιστά τη μοναδική πρακτικά εφαρμόσιμη επιλογή για συστήματα καθημερινής χρήσης, wearable τεχνολογίες και διεπαφές πραγματικού χρόνου.

1.2.1 Μορφές Συστημάτων sEMG

Στη βιβλιογραφία διακρίνονται δύο βασικές κατηγορίες συστημάτων καταγραφής sEMG [1]:

α) Αραιή πολυκαναλική καταγραφή (sparse multi-channel sEMG): Χρησιμοποιεί περιορισμένο αριθμό ηλεκτροδίων (συνήθως 4-12), τα οποία τοποθετούνται στρατηγικά πάνω από συγκεκριμένους μυς-στόχους. Η προσέγγιση αυτή απαιτεί ακριβή ανατομική τοποθέτηση και είναι ευαίσθητη σε μετατοπίσεις των ηλεκτροδίων μεταξύ συνεδριών [1][2]. Παρά τους περιορισμούς και τις δυσκολίες της, παραμένει η πιο διαδεδομένη επιλογή σε εμπορικά συστήματα και προσθετικές εφαρμογές, λόγω της απλότητας και του χαμηλού υπολογιστικού κόστους.

β) Υψηλής πυκνότητας επιφανειακό EMG (High-Density sEMG, HD-sEMG): Βασίζεται σε δισδιάστατες συστοιχίες ηλεκτροδίων (π.χ. 8×16 ή 7×24), οι οποίες παρέχουν λεπτομερή χωρική απεικόνιση της μυϊκής ενεργοποίησης πάνω από την περιοχή κάλυψης. Το HD-sEMG επιτρέπει τη μετατροπή του σήματος σε εικόνες sEMG, ανοίγοντας τον δρόμο για ανάλυση χωρικών μοτίβων που δεν είναι προσβάσιμα μέσω αραιών διατάξεων [1]. Η προσέγγιση αυτή είναι πιο πλούσια σε πληροφορία, αλλά απαιτεί πιο πολύπλοκο εξοπλισμό και υψηλότερο υπολογιστικό κόστος.

1.2.2 Πηγές Θορύβου στο sEMG

Παρά τη χρησιμότητά του, το sEMG σήμα επηρεάζεται από πολλαπλές πηγές θορύβου που υποβαθμίζουν την ποιότητά του και περιορίζουν την αξιοπιστία των εφαρμογών. Οι κυριότερες είναι [3]:

- Motion artifacts (τεχνήματα κίνησης): Παραμορφώσεις που προκαλούνται από τη σχετική κίνηση μεταξύ δέρματος και ηλεκτροδίου ή από μεταβολές στην επαφή ηλεκτροδίου-δέρματος. Εμφανίζονται κυρίως σε χαμηλές συχνότητες (< 20 Hz).
- Crosstalk: Ανάμιξη του σήματος από γειτονικούς μύες, ιδιαίτερα έντονη όταν υπάρχει σημαντικό υποδόριο λίπος ή όταν οι μύες-στόχοι βρίσκονται κοντά σε μεγαλύτερους μυς.
- Power Line Interference (PLI): Παρεμβολή από το ηλεκτρικό δίκτυο στα 50 Hz (Ευρώπη) ή 60 Hz (ΗΠΑ) και τις αρμονικές της. Πρόκειται για μη στάσιμο θόρυβο, με διακυμάνσεις έως ± 2 Hz και μεταβλητό πλάτος, καθιστώντας το φιλτράρισμα του ιδιαίτερα απαιτητικό [3].
- Floating ground noise: Θόρυβος που προέρχεται από την έλλειψη σταθερής γείωσης μεταξύ του υποκειμένου και της διάταξης μέτρησης.
- Μεταβολές επαφής ηλεκτροδίου-δέρματος: Αλλαγές στην αντίσταση επαφής λόγω εφίδρωσης, μετατόπισης ή αποκόλλησης του ηλεκτροδίου.

Η ταυτόχρονη παρουσία αυτών των πηγών καθιστά το sEMG ένα από τα πιο θορυβώδη βιοσήματα, με χαμηλό λόγο σήματος-προς-θόρυβο (SNR) σε σύγκριση με άλλες βιοϊατρικές καταγραφές.

1.2.3 Παράγοντες Μεταβλητότητας του sEMG

Πέρα από τον θόρυβο, το sEMG εμφανίζει εγγενή μεταβλητότητα που σχετίζεται με τις συνθήκες καταγραφής και τις φυσιολογικές διαφορές. Οι κύριοι παράγοντες είναι:

α) Διαφορές μεταξύ χρηστών (Inter-subject variability):

Οι ανατομικές διαφορές μεταξύ ατόμων (όπως το μέγεθος των μυών, το πάχος του υποδόριου λίπους, η κατανομή των κινητικών μονάδων και οι ατομικές στρατηγικές μυϊκής ενεργοποίησης) οδηγούν σε σημαντικές διαφοροποιήσεις στο σήμα ακόμη και για πανομοιότυπες κινήσεις [2]. Αυτό αποτελεί έναν από τους σοβαρότερους περιορισμούς για τη γενίκευση των μοντέλων αναγνώρισης μεταξύ χρηστών.

β) Διαφορές μεταξύ ημερών (Inter-day variability):

Η μεταβλητότητα μεταξύ διαφορετικών συνεδριών καταγραφής οφείλεται κυρίως σε:

- Επανατοποθέτηση των ηλεκτροδίων: Μικρές διαφορές στη θέση των ηλεκτροδίων μεταξύ συνεδριών αλλάζουν τη σχετική θέση τους ως προς τους μύες, μεταβάλλοντας το σήμα.
- Φυσιολογικές μεταβολές: Διαφορές στην ενυδάτωση του δέρματος, τη θερμοκρασία, τη μυϊκή κατάσταση και γενικότερα οποιαδήποτε φυσιολογική διεργασία μπορεί να συμβεί στο σώμα.
- User adaptation: Φαινόμενο κατά το οποίο ο χρήστης τροποποιεί τον τρόπο εκτέλεσης των κινήσεων με την επανάληψη, οδηγώντας σε προοδευτική μεταβολή του σήματος κατά τις πρώτες ημέρες χρήσης [3].

Η inter-day μεταβλητότητα είναι ιδιαίτερα κρίσιμη για εφαρμογές μακροχρόνιας χρήσης, καθώς προκαλεί σημαντική υποβάθμιση της απόδοσης των συστημάτων αναγνώρισης από τη μία ημέρα στην άλλη.

γ) Μεταβλητότητα Στάσης Άκρου (Postural variability):

Η αλλαγή της στάσης του βραχίονα ή του προσανατολισμού του καρπού οδηγεί σε διαφορετική μηχανική ενεργοποίηση των μυών και μεταβολή της σχετικής θέσης τους ως προς τα ηλεκτρόδια. Ως αποτέλεσμα, η ίδια χειρονομία παράγει σημαντικά διαφορετικά σήματα όταν εκτελείται σε διαφορετικές στάσεις [1][3]. Η μεταβλητότητα αυτή είναι αρκετή ώστε να προκαλέσει υποβάθμιση της ακρίβειας έως και 20-30% σε απλές διατάξεις [3].

δ) Μυϊκή κόπωση (muscle fatigue):

Η παρατεταμένη μυϊκή δραστηριότητα οδηγεί σε μεταβολές της αγωγιμότητας της μεμβράνης και της ταχύτητας αγωγής των μυϊκών ινών. Αυτό έχει ως αποτέλεσμα τη μεταβολή στη μορφολογία των MUAPs, με χαρακτηριστικές αλλαγές όπως:

- μείωση της συχνότητας των υψηλών αρμονικών,
- αύξηση του πλάτους,
- μετατόπιση της ενέργειας προς χαμηλότερες συχνότητες.

Τα φαινόμενα αυτά αλλάζουν σημαντικά την κατανομή του σήματος στο χρόνο και το φάσμα, δημιουργώντας δυσκολίες στην αναγνώριση στατικών χειρονομιών σε περιόδους αυξημένης κόπωσης [3].

ε) Μεταβολές ηλεκτρομηχανικής σύζευξης (electromechanical coupling):

Ακόμη και μικρές αλλαγές στη σχέση μεταξύ των μυών, του δέρματος και των ηλεκτροδίων μπορούν να επηρεάσουν την αγωγιμότητα και τη χωρική διάχυση του σήματος. Η σύζευξη αυτή επηρεάζεται από:

- εφίδρωση,
- μικρομετακινήσεις των ηλεκτροδίων,
- αλλαγή στην υφή ή την ενυδάτωση του δέρματος.

Τέτοιες μεταβολές μπορούν να συμβούν ακόμα και εντός της ίδιας συνεδρίας, προκαλώντας σταδιακή μεταβολή του σήματος (signal drift).

1.2.4 Επιπτώσεις της Μεταβλητότητας στη Χρήση του sEMG

Όλοι οι παραπάνω παράγοντες (θόρυβος, φυσιολογικές διαφορές, μετατοπίσεις ηλεκτροδίων, στάση άκρου και κόπωση) έχουν σημαντικές επιπτώσεις στην πρακτική αξιοποίηση του sEMG. Συνολικά, το sEMG θεωρείται ένα από τα πιο μη σταθερά και ευμετάβλητα βιοσήματα μιας και μιλάμε για την περιπλοκότητα της ανθρώπινης ανατομίας, με συνέπειες όπως:

- Μειωμένη επαναληψιμότητα: η ίδια κίνηση μπορεί να παράγει σημαντικά διαφορετικά σήματα σε διαφορετικές στιγμές ή διαφορετικούς χρήστες.
- Περιορισμένη γενίκευση: τα συστήματα που εκπαιδεύονται σε δεδομένα συγκεκριμένης ημέρας ή χρήστη δυσκολεύονται να επεκταθούν σε νέες συνθήκες.
- Ανάγκη για συχνό calibration: πολλές εφαρμογές απαιτούν επαναπροσαρμογή των μοντέλων σε κάθε συνεδρία για να διατηρηθεί η απόδοση [2][3].
- Ασυνεπής αντιστοίχιση σήματος–χειρονομίας: η ίδια χειρονομία μπορεί να οδηγεί σε διαφορετικούς μυϊκούς συνδυασμούς (motor strategies), ειδικά σε άπειρους χρήστες.

Η σύνθετη φύση αυτής της μεταβλητότητας καθιστά σαφές ότι η αναγνώριση χειρονομιών με βάση το sEMG αποτελεί μια δύσκολη και πολυδιάστατη πρόκληση, η οποία απαιτεί ιδιαίτερη μεθοδολογική αντιμετώπιση.

1.2.5 Σημασία του sEMG και Πεδία Εφαρμογής

Παρά την πολυπλοκότητά του, το sEMG αποτελεί θεμελιώδες εργαλείο σε ποικίλους τομείς της βιοϊατρικής τεχνολογίας και της αλληλεπίδρασης ανθρώπου–μηχανής, καθώς στο παρόν στάδιο αποτελεί την πιο πρακτικά αξιοποιήσιμη και μη επεμβατική μέθοδο εκτίμησης της ανθρώπινης πρόθεσης. Οι σημαντικότερες εφαρμογές περιλαμβάνουν [1][2]:

- Έλεγχο προθετικών άκρων: αναγνώριση χειρονομιών για φυσικό και γρήγορο έλεγχο πολυαρθρωτών προσθετικών χεριών.
- Εξωσκελετικούς μηχανισμούς: υποστήριξη κίνησης και αποκατάστασης σε ασθενείς με κινητικές δυσλειτουργίες.
- Αποκατάσταση: παρακολούθηση και καθοδήγηση θεραπευτικών ασκήσεων.
- HCI / MCI (Human/Muscle–Computer Interaction): φυσικές διεπαφές για AR/VR, gaming, βιομετρική αναγνώριση.
- Εργονομική ανάλυση: αξιολόγηση μυϊκού φορτίου και εργονομικού ρίσκου σε εργασιακά περιβάλλοντα.
- Έρευνα νευρομυϊκής φυσιολογίας: ανάλυση ενεργοποίησης μυών και μοτίβων κινητικού ελέγχου.

Η μη επεμβατικότητα, η ευκολία χρήσης και η δυνατότητα φορητής καταγραφής καθιστούν το sEMG ιδιαίτερα ελκυστικό για πρακτικές εφαρμογές.

1.2.6 Συνολική Ερευνητική Πρόκληση

Παρά την τεράστια πρακτική του αξία, το sEMG παραμένει εξαιρετικά δύσκολο σήμα ως προς:

- την επεξεργασία,
- την κατανόηση,
- και την αξιόπιστη αξιοποίησή του σε πραγματικές συνθήκες.

Η βιβλιογραφία συγκλίνει στο ότι το sEMG:

- παρουσιάζει εξαιρετικά υψηλή μεταβλητότητα,
- απαιτεί προσεκτική θεωρητική κατανόηση,
- και αποτελεί πεδίο έντονης έρευνας λόγω του συνδυασμού πλούσιας φυσιολογικής πληροφορίας και θορύβου / αστάθειας / μεταβλητότητας.

Η κατανόηση αυτών των φαινομένων αποτελεί απαραίτητο θεμέλιο για οποιαδήποτε προσπάθεια αναγνώρισης χειρονομιών βασισμένων στο sEMG.

1.3 Η Συμβολή της Βαθιάς Μάθησης (Deep Learning) στην

Αναγνώριση Χειρονομιών

Όπως έχει αναλυθεί εκτενώς στη βιβλιογραφία [1, 2], η στοχαστική φύση και η υψηλή μεταβλητότητα του σήματος sEMG καθιστούν την αξιόπιστη αποκωδικοποίηση της ανθρώπινης πρόθεσης ένα εξαιρετικά περίπλοκο πρόβλημα. Με τη δημιουργία μεγάλων, ανοικτών βάσεων δεδομένων όπως το NinaPro dataset [2], κατέστη σαφές ότι τα συστήματα ελέγχου δυσκολεύονται να διατηρήσουν την απόδοσή τους όταν αντιμετωπίζουν ρεαλιστικές συνθήκες, όπως η αλλαγή στάσης του βραχίονα ή η χρήση του συστήματος σε διαφορετικές ημέρες.

1.3.1 Από την Κλασική Μηχανική Μάθηση στην Αυτόματη Εξαγωγή

Χαρακτηριστικών

Στις παραδοσιακές προσεγγίσεις αναγνώρισης χειρονομιών, η διαδικασία βασιζόταν στην αυστηρή χειροκίνητη εξαγωγή χαρακτηριστικών (hand-crafted features) από το πεδίο του χρόνου ή της συχνότητας. Παρότι μοντέλα της κλασικής μηχανικής μάθησης, όπως τα Support Vector Machines (SVM) με πυρήνα RBF (Radial Basis Function), αποτελούσαν τη βασική γραμμή αναφοράς (baseline) προσφέροντας ικανοποιητικά αποτελέσματα, τα χειροκίνητα χαρακτηριστικά αδυνατούν να προσαρμοστούν επαρκώς στις μη-γραμμικές αλλοιώσεις του σήματος που προκύπτουν από την επανατοποθέτηση των αισθητήρων και τη μυϊκή κόπωση [1]. Για την αντιμετώπιση αυτών των προκλήσεων, η έρευνα έχει στραφεί στα μοντέλα Βαθιάς Μάθησης (Deep

Learning), τα οποία εισάγουν την έννοια της αυτόματης εκμάθησης αναπαραστάσεων (representation learning). Τροφοδοτώντας το δίκτυο με ακατέργαστα (raw) σήματα, το μοντέλο μαθαίνει από μόνο του να αναγνωρίζει τα βέλτιστα και πιο ανθεκτικά χαρακτηριστικά [1, 3].

1.3.2 Χωροχρονική Ανάλυση μέσω CNNs και Ανάλυση Ακολουθιών μέσω TCN

Ανάμεσα στις αρχιτεκτονικές Deep Learning, τα Συνελικτικά Νευρωνικά Δίκτυα (CNNs) κυριαρχούν στην ταξινόμηση βιοσημάτων. Αν και πολλές μελέτες χρησιμοποιούν μονοδιάστατα δίκτυα (1D-CNN) για να επεξεργαστούν το sEMG απλώς ως χρονοσειρά [1], μια σαφώς πιο προηγμένη προσέγγιση είναι η χρήση πολυδιάστατων αρχιτεκτονικών.

Σε αυτή τη μεθοδολογία, το πολυκαναλικό σήμα sEMG δεν αναλύεται στην ακατέργαστη μορφή του, αλλά μετασχηματίζεται μέσω του Βραχυπρόθεσμου Μετασχηματισμού Fourier (STFT) σε δισδιάστατα φασματογραφήματα (spectrograms). Αυτή η διαδικασία αναδιοργανώνει την πληροφορία σε μορφή «εικόνας», η οποία αποτυπώνει ταυτόχρονα τη χρονική εξέλιξη και το συχνотικό περιεχόμενο του σήματος. Εφαρμόζοντας πολυδιάστατα δίκτυα (2D και 3D-CNNs), οι πυρήνες συνέλιξης σαρώνουν ταυτόχρονα αυτούς τους άξονες (χρόνο, συχνότητα και κανάλια αισθητήρων). Αυτό επιτρέπει στο μοντέλο να εξάγει σύνθετα χωροχρονικά χαρακτηριστικά (spatiotemporal features), μαθαίνοντας δηλαδή όχι μόνο πώς εξελίσσεται το σήμα χρονικά, αλλά και ποιες μυϊκές συνέργειες αναπτύσσονται συγχρονισμένα μεταξύ διαφορετικών μυών [3]. Μέσω των διαδοχικών επιπέδων συνέλιξης και κανονικοποίησης, τα πολυδιάστατα CNNs κατορθώνουν να συλλάβουν κρυμμένα, υψηλής αφαιρετικότητας κινητικά μοτίβα, τα οποία οι κλασικές μονοδιάστατες μέθοδοι αδυνατούσαν να εντοπίσουν [3].

Μια εναλλακτική και συμπληρωματική προσέγγιση είναι τα Χρονικά Συνελικτικά Δίκτυα (Temporal Convolutional Networks, TCN) [5], τα οποία επεξεργάζονται απευθείας το ακατέργαστο (raw) πολυκαναλικό σήμα sEMG, χωρίς προηγούμενο μετασχηματισμό STFT. Τα TCN χρησιμοποιούν αιτιώδεις διεσταλμένες μονοδιάστατες συνέλιξεις (causal dilated 1D convolutions), οι οποίες εξασφαλίζουν ότι κάθε πρόβλεψη βασίζεται αποκλειστικά σε παρελθοντικά δείγματα, διατηρώντας έτσι

την αιτιώδη δομή του σήματος. Μέσω της εκθετικής αύξησης του συντελεστή διαστολής (dilation) σε διαδοχικά επίπεδα, το δίκτυο αποκτά μεγάλο αποδεκτικό πεδίο (receptive field) με ελάχιστες παραμέτρους, καθιστώντας το εξαιρετικά αποδοτικό για ανάλυση χρονικών εξαρτήσεων σε βιοσήματα [5].

1.3.3 Υπέρβαση των Περιορισμών Υλικού: Ενέργεια, Κόστος και Edge AI

Παρά την ισχυρή ικανότητα γενίκευσης των πολυδιάστατων CNNs απέναντι στη μεταβλητότητα του σήματος [1, 3], η πρακτική τους εφαρμογή συναντά ένα σημαντικό «τείχος»: τα δίκτυα αυτά (ειδικά οι 3D αρχιτεκτονικές) είναι εξαιρετικά απαιτητικά σε υπολογιστικούς πόρους, μνήμη και ενέργεια. Για τα συστήματα Human-Machine Interfaces (HMIs), όπως οι πολυαρθρωτές προθέσεις, τα οποία πρέπει να λειτουργούν ως αυτόνομα ενσωματωμένα συστήματα (embedded systems) τροφοδοτούμενα από μπαταρία, οι παραδοσιακές «βαριές» αρχιτεκτονικές είναι απαγορευτικές [1]. Εδώ έγκειται και η καινοτομία της σύγχρονης έρευνας στον τομέα του Edge AI, όπου η τεχνητή νοημοσύνη εκτελείται απευθείας στον μικροελεγκτή (on-device inference). Για να αξιοποιηθεί η διαγνωστική δύναμη των πολυδιάστατων CNNs, απαιτείται ο σχεδιασμός «ελαφριών» (lightweight) αρχιτεκτονικών, οι οποίες μειώνουν δραματικά τον αριθμό των παραμέτρων και των μαθηματικών πράξεων (FLOPs). Αυτή η βελτιστοποίηση διασφαλίζει ότι η εξαγωγή πληροφορίας και η πρόβλεψη ολοκληρώνονται ταχύτατα, διατηρώντας τη συνολική καθυστέρηση (latency) εντός των αυστηρών ορίων του πραγματικού χρόνου (< 300 ms), μειώνοντας ταυτόχρονα την κατανάλωση ισχύος [1].

1.4 Μεθοδολογική Προσέγγιση και Σημασία της Εργασίας

Βασιζόμενη στα παραπάνω δεδομένα, η παρούσα εργασία φιλοδοξεί να γεφυρώσει το κενό μεταξύ της υψηλής ακρίβειας που προσφέρουν τα δίκτυα βαθιάς μάθησης και της ανάγκης για υπολογιστική αποδοτικότητα σε ρεαλιστικές συνθήκες πραγματικού χρόνου. Η καινοτομία της εργασίας έγκειται στη συγκριτική ανάπτυξη και αξιολόγηση τεσσάρων αρχιτεκτονικών νευρωνικών δικτύων που αντιπροσωπεύουν δύο θεμελιωδώς διαφορετικές προσεγγίσεις επεξεργασίας sEMG.

Η πρώτη προσέγγιση βασίζεται στη μετατροπή του σήματος σε φασματογραφήματα STFT και στην επακόλουθη επεξεργασία τους με πολυδιάστατα CNN: η αρχιτεκτονική

SlowFusion εκπαιδεύεται εξ αρχής αξιοποιώντας 3D συνελίξεις για σταδιακή χρονική συγχώνευση, ενώ το MobileNetV2 εφαρμόζει Μεταφορά Μάθησης (Transfer Learning) από προ-εκπαιδευμένα βάρη ImageNet σε μια ελαφριά 2D-CNN αρχιτεκτονική. Η δεύτερη προσέγγιση αξιοποιεί απευθείας το ακατέργαστο πολυκαναλικό σήμα EMG μέσω Χρονικών Συνελικτικών Δικτύων (TCN), σε δύο παραλλαγές που διαφέρουν ως προς τον μηχανισμό χρονικής συνάθροισης: απλός μέσος όρος χρονικής κατανομής (TCN-AoT) και μηχανισμός προσοχής (TCN-Att). Στόχος είναι να διερευνηθεί πώς κάθε προσέγγιση αντιμετωπίζει την εγγενή μεταβλητότητα του σήματος sEMG, παραμένοντας παράλληλα αυστηρά εντός των προδιαγραφών που απαιτούνται για ενσωματωμένα συστήματα HMI πραγματικού χρόνου.

1.5 Ερευνητικά Ερωτήματα

Με βάση το παραπάνω πλαίσιο, η παρούσα εργασία καλείται να απαντήσει στα ακόλουθα κεντρικά ερευνητικά ερωτήματα:

1. Πώς συγκρίνεται η διαγνωστική ακρίβεια των αρχιτεκτονικών βασισμένων σε φασματογραφήματα STFT (SlowFusion 3D-CNN, MobileNetV2) έναντι των αρχιτεκτονικών επεξεργασίας ακατέργαστου σήματος (TCN), κατά την ταξινόμηση πολύπλοκων χειρονομιών υπό την παρουσία της εγγενούς μεταβλητότητας του σήματος sEMG;
2. Σε ποιο βαθμό μπορεί η τεχνική της Μεταφοράς Μάθησης (Transfer Learning) από άλλα πεδία (π.χ. αναγνώριση εικόνων) να βελτιώσει την απόδοση ελαφριών δικτύων στα βιοσήματα, και πώς συγκρίνεται η προσέγγιση αυτή με αρχιτεκτονικές εκπαιδευόμενες εξ αρχής (from scratch) σε raw EMG;
3. Ποιος μηχανισμός χρονικής συνάθροισης (απλός μέσος όρος (Average-over-Time) ή μηχανισμός προσοχής (Attention)) αποδεικνύεται αποτελεσματικότερος στο πλαίσιο TCN για ακολουθίες sEMG;
4. Είναι εφικτή η υλοποίηση όλων των προτεινόμενων αρχιτεκτονικών υπό τις αυστηρές προδιαγραφές ενός συστήματος ελέγχου πραγματικού χρόνου,

ικανοποιώντας τον περιορισμό συνολικής καθυστέρησης (latency) κάτω των 300 ms (και inference pipeline < 40 ms);

2

Υλικό και Μέθοδοι

2.1 Περιγραφή του Συνόλου Δεδομένων (NinaPro DB5) και

Διαχωρισμός (Split)

Για την εκπαίδευση και την αξιολόγηση των αρχιτεκτονικών νευρωνικών δικτύων που αναπτύχθηκαν στην παρούσα εργασία, επιλέχθηκε η δημόσια βάση δεδομένων NinaPro DB5, η οποία αποτελεί αναγνωρισμένο πρότυπο για την αξιολόγηση αλγορίθμων αναγνώρισης χειρονομιών βασισμένων στο sEMG. Βασική βιβλιογραφική πηγή για την ανάλυση του dataset και της χρήσης του αποτελεί η πηγή [4].

2.1.1. Συμμετέχοντες και Συσκευές-Εξοπλισμός Καταγραφής

Τα δεδομένα που αξιοποιούνται στην παρούσα εργασία προέρχονται από καταγραφές που πραγματοποιήθηκαν σε ένα υποσύνολο πέντε (5) αρτιμελών συμμετεχόντων (Subject 1 έως Subject 5) από τη δημόσια βάση δεδομένων NinaPro DB5 (η οποία αρχικά διαθέτει δέκα (10) συμμετέχοντες). Αν και το αρχικό πρωτόκολλο συλλογής προέβλεπε την τοποθέτηση δύο συσκευών Myo Armband στον πήχη κάθε συμμετέχοντα, στην παρούσα εργασία, σε ευθυγράμμιση με τη σχετική βιβλιογραφία και με στόχο τη βελτιστοποίηση του υπολογιστικού κόστους, αξιοποιούνται αποκλειστικά τα δεδομένα από τη χαμηλότερη διάταξη (lower armband), παρέχοντας συνολικά οκτώ (8) κανάλια καταγραφής.

Η συσκευή Myo Armband αποτελεί μια διάταξη sEMG χαμηλού κόστους, η οποία ενσωματώνει ξηρά ηλεκτρόδια (dry electrodes) και λειτουργεί με συχνότητα δειγματοληψίας 200 Hz. Η χρήση ξηρών ηλεκτροδίων καθιστά τη συσκευή εξαιρετικά πρακτική, καθώς επιτρέπει την άμεση εφαρμογή της χωρίς να απαιτείται καμία προεργασία του δέρματος του χρήστη (όπως ξύρισμα ή καθαρισμός). Εντούτοις, η συγκεκριμένη ευκολία χρήσης συνοδεύεται από σημαντικούς περιορισμούς, καθώς τα ξηρά ηλεκτρόδια παρουσιάζουν μειωμένη ακρίβεια και είναι περισσότερο ευαίσθητα

σε τεχνικά σφάλματα κίνησης (motion artifacts) σε σύγκριση με τα ηλεκτρόδια τζελ (gel-based electrodes).

Επιπλέον, δεδομένου ότι το χρήσιμο εύρος συχνοτήτων για τα σήματα sEMG εκτείνεται από 5 έως 500 Hz, γεγονός που απαιτεί συχνότητα δειγματοληψίας μεγαλύτερη από 1000 Hz βάσει του θεωρήματος Nyquist για την αποφυγή φαινομένων αναδίπλωσης (aliasing), ο περιορισμός των 200 Hz της συσκευής Myo οδηγεί αναπόφευκτα σε εκτεταμένη απώλεια πληροφορίας. Αυτή η υποδειγματοληψία υποβαθμίζει τον λόγο σήματος-προς-θόρυβο (SNR) και δυσχεραίνει τη διάκριση των χαρακτηριστικών στο σήμα, καθιστώντας ιδιαίτερα χρήσιμη την εφαρμογή προηγμένων αρχιτεκτονικών Βαθιάς Μάθησης για την αποτελεσματική εξαγωγή προτύπων.

2.1.2. Κινήσεις και Πειράματα κατά την καταγραφή

Το πλήρες σύνολο δεδομένων NinaProDB5 περιλαμβάνει συνολικά 53 διαφορετικές κινήσεις (52 κινήσεις + ανάπαυση) χωρισμένες σε 3 σετ ασκήσεων. Ωστόσο, στη συγκεκριμένη ανάλυση (βασιζόμενοι και στην βιβλιογραφία) αξιοποιείται μόνο το 2ο σετ ασκήσεων, το οποίο εμφανίζει μεγάλο πρακτικό ενδιαφέρον καθώς περιλαμβάνει 17 βασικές χειρονομίες συν την χειρονομία ανάπαυσης. Η επιλογή αυτή βασίζεται σε κριτήρια κλινικής και λειτουργικής σκοπιμότητας, καθώς το συγκεκριμένο σετ εστιάζει στις πλέον απαραίτητες χειρονομίες για την καθημερινή αυτόνομη διαβίωση ενός χρήστη προθετικού μέλους.

Κατά τη διάρκεια της πειραματικής διαδικασίας, ο εκάστοτε συμμετέχων κλήθηκε να διατηρήσει την επιθυμητή χειρονομία σταθερή για πέντε (5) δευτερόλεπτα, ακολουθούμενη από τρία (3) δευτερόλεπτα ανάπαυσης, με τη διαδικασία να επαναλαμβάνεται έξι (6) συνολικά φορές για κάθε κίνηση.

2.1.3. Μορφή των ακατέργαστων δεδομένων στο dataset

Τα δεδομένα της βάσης παρέχονται σε αρχεία τύπου .mat, τα οποία αποτυπώνουν την ακατέργαστη (raw) ηλεκτρομυογραφική δραστηριότητα σε μορφή 1D χρονοσειρών. Μαθηματικά, τα σήματα sEMG αναπαρίστανται ως ένας πίνακας διαστάσεων $N \times 8$, όπου N είναι το πλήθος των χρονικών δειγμάτων και 8 τα κανάλια καταγραφής της χαμηλότερης συσκευής Myo Armband.

Επιπλέον, τα αρχεία περιλαμβάνουν διανύσματα συγχρονισμού (ίδιου μήκους N) που καταγράφουν την ετικέτα της κίνησης (stimulus) και τον αριθμό της επανάληψης

(repetition) για κάθε δείγμα. Επειδή, λοιπόν, η αρχική αυτή πληροφορία αφορά αποκλειστικά το πεδίο του χρόνου, καθίσταται αναγκαία η προεπεξεργασία των δεδομένων πριν την τροφοδότησή τους στα μοντέλα. Ανάλογα με την αρχιτεκτονική, τα δεδομένα μετασχηματίζονται είτε σε τρισδιάστατο τανυστή φασματογραφήματος STFT [αρχιτεκτονικές A και B], είτε χρησιμοποιούνται απευθείας ως ακατέργαστο πολυκαναλικό σήμα [αρχιτεκτονική C], όπως αναλύεται στην ενότητα 2.2.

2.1.4. Διαχωρισμός δεδομένων σε training και test set

Η στρατηγική κατανομής των δεδομένων στα σύνολα εκπαίδευσης (training set) και δοκιμής (test set) σχεδιάστηκε με γνώμονα την πλήρη εξάλειψη του φαινομένου της διαρροής πληροφορίας (data leakage) και την αντικειμενική αξιολόγηση της γενικευτικής ικανότητας του μοντέλου. Αντί για μια τυχαία στοχαστική κατανομή δειγμάτων, ο διαχωρισμός πραγματοποιήθηκε βάσει των διακριτών επαναλήψεων εκτέλεσης των χειρονομιών. Πιο συγκεκριμένα, για κάθε έναν από τους πέντε (5) χρήστες και για το σύνολο των 17 κινητικών κλάσεων, οι επαναλήψεις 1, 3, 4, 6 δεσμεύτηκαν για την εκπαίδευση του δικτύου, ενώ οι επαναλήψεις 2, 5 απομονώθηκαν εξ αρχής για τη φάση της δοκιμής. Ο συγκεκριμένος ντετερμινιστικός διαχωρισμός διασφαλίζει ότι τα δίκτυα αξιολογούνται σε χρονικά ανεξάρτητα δείγματα sEMG, συμβάλλοντας έτσι στην προσπάθεια αποφυγής της υπερεκπαίδευσης του μοντέλου.

2.2 Προεπεξεργασία (Preprocessing) και Εξαγωγή

Χαρακτηριστικών (Feature Extraction)

Τα ακατέργαστα (raw) σήματα sEMG που εξάγονται από τη βάση δεδομένων χαρακτηρίζονται εγγενώς από υψηλά επίπεδα θορύβου, καθιστώντας απαραίτητη την προεπεξεργασία τους πριν την τροφοδότησή τους στα μοντέλα Βαθιάς Μάθησης. Η ροή προεπεξεργασίας αποτελείται από δύο κοινά στάδια που εφαρμόζονται σε όλες τις αρχιτεκτονικές, και ένα τρίτο στάδιο που διαφοροποιείται ανάλογα με τον τύπο εισόδου που απαιτεί κάθε αρχιτεκτονική:

- 1. Ψηφιακό Φιλτράρισμα:** Σε πρώτο στάδιο, εφαρμόζεται στα σήματα sEMG ένα ψηφιακό φίλτρο αποκοπής ζώνης μηδενικής φάσης Notch (zero-phase IIR Notch filter) με κεντρική συχνότητα 50 Hz και συντελεστή ποιότητας $Q=30$. Σκοπός της χρήσης αυτού του φίλτρου είναι η εξάλειψη του θορύβου και των παρεμβολών από το ηλεκτρικό δίκτυο, εξασφαλίζοντας μηδενική επίδραση στη

φάση των σημάτων και επομένως στην χρήσιμη πληροφορία της μυϊκής σύσπασης.

2. **Φιλτράρισμα Κλάσης Ανάπαυσης:** Μετά τη δημιουργία των παραθύρων, όλα τα windows που αντιστοιχούν στην κλάση ανάπαυσης (label=0) αφαιρούνται από το dataset. Οι υπόλοιπες ετικέτες (1-17) αναδιοργανώνονται στο εύρος 0-16 για συμβατότητα με τα νευρωνικά δίκτυα. Αυτή η επιλογή απλοποιεί το πρόβλημα σε καθαρή ταξινόμηση 17 ενεργών χειρονομιών.
3. **Χρονική Παραθύρωση (Sliding Window):** Για να εξασφαλιστεί η δυνατότητα ελέγχου σε πραγματικό χρόνο (real-time prediction), το συνεχές φιλτραρισμένο σήμα τεμαχίζεται σε επικαλυπτόμενα χρονικά παράθυρα (overlapping windows). Το μέγεθος κάθε παραθύρου ορίστηκε να καλύπτει 52 δείγματα. Δεδομένου ότι η συσκευή Myo δειγματοληπτεί με συχνότητα 200 Hz, τα δείγματα αυτά αντιστοιχούν σε χρονική διάρκεια 260 ms. Μάλιστα, το βήμα ολίσθησης (sliding step) ορίστηκε στα 5 δείγματα (25 ms), με αποτέλεσμα να εμφανίζεται επικάλυψη 47 δειγμάτων (235 ms) με γειτονικά παράθυρα ώστε να εκμηδενιστεί ο κίνδυνος απώλειας χρήσιμης πληροφορίας. Η επιλογή των 260 ms προσφέρει επαρκή στατιστική πληροφορία στο μοντέλο, ενώ παράλληλα αφήνει το αναγκαίο χρονικό περιθώριο για την υπολογιστική εξαγωγή της πρόβλεψης (inference latency), διατηρώντας τον συνολικό χρόνο απόκρισης του συστήματος κάτω από το καθιερωμένο όριο των 300 ms. Αξίζει να σημειωθεί, ωστόσο, ότι σύμφωνα με πρόσφατες βιβλιογραφικές μελέτες, η ιδανική καθυστέρηση για μια απολύτως φυσική αλληλεπίδραση (seamless interaction) προτείνεται να κυμαίνεται στο αυστηρότερο εύρος των 100-250 ms. Το γεγονός αυτό εγείρει νέους επιστημονικούς προβληματισμούς, αναδεικνύοντας έναν εγγενή συμβιβασμό (trade-off) μεταξύ της ταχύτητας απόκρισης και της διαγνωστικής ακρίβειας του δικτύου. Στο πλαίσιο της παρούσας μελέτης, ωστόσο, δίνεται προτεραιότητα στη μεγιστοποίηση της ακρίβειας ταξινόμησης έναντι του υπολογιστικού χρόνου, υιοθετώντας το ευρύτερα αποδεκτό και πιο ευέλικτο όριο των 300 ms.
4. **Μετασχηματισμός Δεδομένων, Δύο Paths:** Μετά την παραθύρωση, η μορφή της εισόδου διαφοροποιείται ανάλογα με την αρχιτεκτονική:

4a. STFT Φασματογράφημα [Αρχιτεκτονικές A, B]: Για τις αρχιτεκτονικές SlowFusion και MobileNetV2, κάθε παράθυρο σχήματος (52, 8) μετασχηματίζεται

μέσω του Βραχυπρόθεσμου Μετασχηματισμού Fourier (STFT) σε φασματογράφημα. Ο μετασχηματισμός εφαρμόζεται ανά κανάλι χρησιμοποιώντας παράθυρα Hann μήκους 28 δειγμάτων με επικάλυψη 20 δειγμάτων. Από το παραγόμενο φάσμα απορρίπτεται η πρώτη ζώνη συχνοτήτων (DC bin) για να ελαχιστοποιηθεί η επίδραση της ολίσθησης της γραμμής βάσης και των τεχνουργημάτων κίνησης, και εφαρμόζεται λογαριθμική συμπίεση ($\log_{10}$). Ως αποτέλεσμα, κάθε παράθυρο αναδιοργανώνεται σε τανυστή διαστάσεων (4, 8, 14) ((Χρόνος, Κανάλια, Συχνότητα)) που αποτελεί την είσοδο για τις CNN αρχιτεκτονικές. Με $nperseg=28$ και $noverlap=20$, το STFT χωρίζει το window των 52 δειγμάτων σε 4 χρονικά frames ($step=8$ samples). Το frequency spectrum περιέχει αρχικά 15 bins (0-14), από τα οποία απορρίπτεται το πρώτο (DC bin), αφήνοντας 14 χρήσιμες συχνοτικές ζώνες. Τα 8 κανάλια αντιστοιχούν στα 8 ηλεκτρόδια του Myo Armband. Έτσι προκύπτει το τελικό σχήμα (4, 8, 14) ανά παράθυρο.

4β. Raw EMG [Αρχιτεκτονική C]: Για τα TCN, δεν απαιτείται κανένας φασματικός μετασχηματισμός. Κάθε παράθυρο σχήματος (52, 8) απλώς μεταφέρεται (transpose) στη μορφή (8, 52) ((Κανάλια, Χρόνος)) που αποτελεί την απευθείας είσοδο στο δίκτυο. Αυτή η απλή μετατροπή έχει αμελητέο υπολογιστικό κόστος (~ 0.01 ms), αποτελώντας σημαντικό πλεονέκτημα για εφαρμογές πραγματικού χρόνου.

2.3 Αρχιτεκτονική Νευρωνικών Δικτύων

Για την ταξινόμηση των σημάτων sEMG σε 17 διακριτές χειρονομίες, υλοποιήθηκαν και αξιολογήθηκαν συγκριτικά τέσσερις αρχιτεκτονικές νευρωνικών δικτύων, εντασσόμενες σε δύο θεμελιωδώς διαφορετικές προσεγγίσεις: επεξεργασία φασματογραφημάτων STFT μέσω CNN (SlowFusion, MobileNetV2) και επεξεργασία ακατέργαστου σήματος μέσω TCN (TCN-AoT, TCN-Att). Στόχος αυτής της πολυδιάστατης σύγκρισης είναι η μελέτη της ισορροπίας (trade-off) μεταξύ διαγνωστικής ακρίβειας, υπολογιστικού κόστους και απλότητας pipeline.

2.3.1 Αρχιτεκτονική Σταδιακής Συγχώνευσης (Slow Fusion CNN)

Η πρώτη προσέγγιση αποτελεί ένα εξειδικευμένο τρισδιάστατο συνελκτικό δίκτυο (3D-CNN), εμπνευσμένο από τη μεθοδολογία των Côté-Allard [4] κ.ά.. Το μοντέλο αυτό εκπαιδεύεται εξ αρχής (from scratch) και βασίζεται στην αρχή της σταδιακής χρονικής συγχώνευσης (progressive temporal fusion). Αντί το δίκτυο να αναλύσει ολόκληρο το χρονικό παράθυρο σε ένα μόνο βήμα, χρησιμοποιεί τρία διαδοχικά μπλοκ τρισδιάστατης συνέλιξης (Conv3D), τα οποία συμπύκνουν τον άξονα του χρόνου προοδευτικά:

- Στο πρώτο επίπεδο, η συνέλιξη εφαρμόζεται με χρονικό πυρήνα (temporal kernel) μεγέθους 1, αναλύοντας κάθε χρονικό πλαίσιο ανεξάρτητα.
- Στα επόμενα δύο επίπεδα, χρησιμοποιείται χρονικός πυρήνας μεγέθους 2, επιτρέποντας τη σταδιακή συγχώνευση της πληροφορίας γειτονικών πλαισίων, μέχρι ο χρονικός άξονας να καταρρεύσει πλήρως σε ένα ενιαίο διάνυσμα χαρακτηριστικών.

Αυτή η προσέγγιση επιτρέπει στο δίκτυο να εντοπίζει πολύπλοκες και συγχρονισμένες μυϊκές συνέργειες, ενώ για την αποτροπή της υπερεκπαίδευσης (overfitting) εφαρμόζεται τεχνική Dropout με πιθανότητα 50% στο τελικό επίπεδο ταξινόμησης.

2.3.2 Αρχιτεκτονική MobileNetV2 και Transfer Learning

Η δεύτερη, και πλέον σύγχρονη, προσέγγιση αξιοποιεί την αρχιτεκτονική MobileNetV2, η οποία είναι ειδικά βελτιστοποιημένη για συστήματα Edge AI με αυστηρούς περιορισμούς μνήμης και επεξεργαστικής ισχύος. Δεδομένου ότι ο όγκος των δεδομένων sEMG ανά χρήστη είναι σχετικά περιορισμένος, εφαρμόστηκε η τεχνική της Μεταφοράς Μάθησης (Transfer Learning) [4]. Το δίκτυο αρχικοποιήθηκε με προ-εκπαιδευμένα βάρη (pre-trained weights) από την ευρείας κλίμακας βάση εικόνων ImageNet.

Για την προσαρμογή της αρχιτεκτονικής στα δεδομένα του sEMG, πραγματοποιήθηκαν οι εξής στοχευμένες τροποποιήσεις:

1. Ο τετραδιάστατος τανυστής εισόδου STFT σχήματος (**N, 4, 8, 14**) αναδιοργανώνεται σε μορφή εικόνας EMG ως εξής: αρχικά γίνεται permute σε (**N, 8, 4, 14**) και reshape σε (**N, 1, 8, 56**), όπου οι γραμμές αντιστοιχούν στα 8 ηλεκτρόδια και οι στήλες στη συνένωση χρονικών πλαισίων και ζωνών συχνοτήτων. Στη συνέχεια, η εικόνα αναπαράχθηκε σε 3 κανάλια και υπέστη διγραμμική παρεμβολή (bilinear interpolation) ώστε να αποκτήσει χωρική

- διάσταση 64×64 , αποτρέποντας την πρόωρη χωρική κατάρρευση (spatial collapse) στα βαθύτερα επίπεδα του δικτύου.
2. Το πρώτο συνελικτικό επίπεδο διατηρήθηκε αναλλοίωτο με τα προ-εκπαιδευμένα βάρη ImageNet (3 κανάλια εισόδου), καθώς η αναπαραγωγή σε 3 κανάλια επιτρέπει την πλήρη αξιοποίηση των αρχικών βαρών χωρίς επανεκκίνηση με τη μέθοδο Kaiming, διατηρώντας έτσι τη γνώση χαμηλού επιπέδου από το ImageNet.
 3. Τα πρώτα 7 επίπεδα εξαγωγής χαρακτηριστικών του δικτύου «πάγωσαν» (frozen layers) κατά τη διάρκεια της εκπαίδευσης. Με τον τρόπο αυτό, το μοντέλο διατήρησε την ικανότητα αναγνώρισης γενικών δομικών χαρακτηριστικών (όπως ακμές και διαβαθμίσεις), επιτρέποντας τη μικρο-ρύθμιση (fine-tuning) αποκλειστικά των βαθύτερων επιπέδων και του νέου, ειδικά σχεδιασμένου ταξινομητή των 17 κλάσεων.

2.3.3 Αρχιτεκτονικές *Temporal Convolutional Networks*

Η τρίτη προσέγγιση βασίζεται στην αρχιτεκτονική Temporal Convolutional Network (TCN), όπως προτάθηκε από τους Tsinganos et al. [5] για την αναγνώριση χειρονομιών από σήματα sEMG. Σε αντίθεση με τις δύο προηγούμενες αρχιτεκτονικές, η TCN δέχεται ως είσοδο απευθείας τα ακατέργαστα χρονικά παράθυρα σχήματος (**N, 8, 52**), παρακάμπτοντας εξ ολοκλήρου το στάδιο εξαγωγής χαρακτηριστικών STFT.

Ο πυρήνας της αρχιτεκτονικής αποτελείται από στοίβα Temporal Blocks, καθένα εκ των οποίων περιλαμβάνει δύο (2) αιτιοκρατικές (causal) dilated συνελίξεις μονής διάστασης με εκθετικά αυξανόμενο παράγοντα διαστολής $d = 2^i$, BatchNorm, ReLU και Dropout. Κάθε Temporal Block περιλαμβάνει dropout με πιθανότητα 0.05 μετά από κάθε ReLU activation, παρέχοντας ήπια regularization χωρίς να επιβραδύνει τη σύγκλιση. Η χρήση causal συνελίξεων εξασφαλίζει ότι κάθε έξοδος εξαρτάται αποκλειστικά από παρελθοντικές και τρέχουσες εισόδους, ενώ οι συνδέσεις παράλειψης (residual connections) σταθεροποιούν την εκπαίδευση σε βαθύτερες στοίβες. Με 4 επίπεδα και μέγεθος πυρήνα 3, το receptive field ανέρχεται σε 30 δείγματα, που αντιστοιχούν σε 150ms στα 200Hz, επαρκές για την κάλυψη του window size των 52 δειγμάτων (260ms).

Υλοποιήθηκαν δύο εναλλακτικοί ταξινομητές επί της εξόδου της TCN:

- TCN-AoT: ο μέσος όρος των χαρακτηριστικών κατά τον χρονικό άξονα (Average-over-Time), ο οποίος παράγει έναν σταθερού μεγέθους διάνυσμα ανεξαρτήτως μήκους ακολουθίας.
- TCN-Att: μηχανισμός προσοχής (attention) βάσει διανύσματος πλαισίου u_a , ο οποίος εκχωρεί βαρύτητα σε κάθε χρονικό βήμα αναλόγως της διακριτικής του αξίας για την τελική ταξινόμηση.

2.4 Εκπαίδευση και Κριτήρια Αξιολόγησης Μοντέλων

Η διαδικασία εκπαίδευσης, επικύρωσης και τελικής αξιολόγησης των τεσσάρων αρχιτεκτονικών (SlowFusion 3D-CNN, MobileNetV2, TCN-AoT και TCN-Att) υλοποιήθηκε εξ ολοκλήρου στο υπολογιστικό περιβάλλον PyTorch.

2.4.1 Περιβάλλον Εκπαίδευσης και Διαμόρφωση Δεδομένων

Η εκπαίδευση εκτελείται ξεχωριστά για κάθε έναν από τους πέντε (5) συμμετέχοντες (per-subject training), σε συμφωνία με τη μεθοδολογία της βιβλιογραφίας αναφοράς [4], καθώς τα σήματα sEMG παρουσιάζουν σημαντική διακύμανση μεταξύ χρηστών και η αξιολόγηση πραγματοποιείται σε ενδο-υποκειμενικό (intra-subject) πλαίσιο. Από το σύνολο εκπαίδευσης κάθε subject, ένα τυχαίο 10% δεσμεύεται ως σύνολο επικύρωσης (validation set) για την παρακολούθηση της πορείας σύγκλισης, ενώ το υπόλοιπο 90% χρησιμοποιείται για την ενημέρωση των βαρών. Τα δεδομένα τροφοδοτούνται στο δίκτυο σε mini-batches μεγέθους 128 δειγμάτων, με τυχαία ανακατανομή (shuffling) σε κάθε εποχή ώστε να αποφεύγεται η εξάρτηση από τη σειρά παρουσίασης.

2.4.2 Συνάρτηση Κόστους και Βελτιστοποιητής

Ως συνάρτηση κόστους χρησιμοποιείται η Cross-Entropy Loss, η οποία αποτελεί την κατάλληλη επιλογή για προβλήματα multi-class ταξινόμησης, καθώς τιμωρεί αναλογικά τις εσφαλμένες προβλέψεις υψηλής εμπιστοσύνης. Ως αλγόριθμος βελτιστοποίησης επιλέχθηκε ο Adam (Adaptive Moment Estimation), με αρχικό ρυθμό μάθησης $lr = 0.00681$, τιμή που υιοθετήθηκε από τη βιβλιογραφία αναφοράς [4] και έχει βρεθεί μέσω τυχαίας αναζήτησης υπερπαραμέτρων (random search).

Για την αρχιτεκτονική MobileNetV2, εφαρμόζεται στρατηγική διαφοροποιημένων ρυθμών μάθησης (differential learning rates) ανά ομάδα επιπέδων, προκειμένου να σεβαστεί την ιεραρχία των προ-εκπαιδευμένων χαρακτηριστικών: τα ενδιάμεσα επίπεδα εκπαιδεύονται με ρυθμό $lr \times 0.01$, τα ανώτερα επίπεδα με $lr \times 0.1$, και ο τελικός ταξινομητής με τον πλήρη ρυθμό lr . Η προσέγγιση αυτή διασφαλίζει ότι τα γενικά χαρακτηριστικά χαμηλού επιπέδου (ακμές, υφές) που έχουν ήδη μάθει τα παγωμένα layers διατηρούνται ανέπαφα, ενώ τα βαθύτερα layers προσαρμόζονται στα δεδομένα sEMG με ελεγχόμενο ρυθμό.

Για την αρχιτεκτονική TCN, η εκπαίδευση ακολουθεί τις υπερπαραμέτρους του [5]: optimizer Adam με αρχικό ρυθμό μάθησης 0.01, 60 εποχές και μέγεθος δέσμης 128.

Για τις αρχιτεκτονικές TCN, ο ρυθμός μάθησης ορίζεται σε **0.01**, σύμφωνα με τη βιβλιογραφία [5], υψηλότερος από τις STFT-based προσεγγίσεις λόγω της πιο άμεσης σχέσης εισόδου-εξόδου στο raw EMG σήμα.

2.4.3 Στρατηγική Πρώιμης Διακοπής (Early Stopping)

Για την αποφυγή υπερεκπαίδευσης (overfitting), υιοθετείται μηχανισμός πρώιμης διακοπής βασισμένος στην παρακολούθηση της απώλειας επικύρωσης (validation loss). Συγκεκριμένα, χρησιμοποιείται ο προγραμματιστής ReduceLROnPlateau, ο οποίος μειώνει τον ρυθμό μάθησης κατά συντελεστή 0.2 (δηλαδή $lr \leftarrow lr / 5$) όταν η απώλεια επικύρωσης δεν βελτιώνεται για 3 συνεχόμενες εποχές στην περίπτωση του SlowFusion ή για 5 εποχές στην περίπτωση του MobileNetV2 και των TCN. Η μεγαλύτερη ανοχή για το MobileNetV2 και τα TCN δικαιολογείται από την πιο αργή σύγκλιση των τριών διαφοροποιημένων ομάδων παραμέτρων στην περίπτωση του MobileNetV2, και από τη μεγαλύτερη ευαισθησία των TCN σε αλλαγές του learning rate λόγω της αιτιώδους δομής τους.

Η εκπαίδευση διακόπτεται αυτόματα μετά από 2 διαδοχικές μειώσεις του ρυθμού μάθησης για το SlowFusion και τα TCN, και 3 για το MobileNetV2, κριτήριο που αντικατοπτρίζει τη στασιμότητα της σύγκλισης. Ο μηχανισμός αυτός, εμπνευσμένος από τη μεθοδολογία του [1], αντικαθιστά το απλό patience-based early stopping και αποδεικνύεται πιο ανθεκτικός σε τοπικές διακυμάνσεις της απώλειας. Το ανώτατο όριο εποχών ορίζεται στις 30 για το SlowFusion και στις 60 για το MobileNetV2 και τα TCN (AoT, Att). Το τελικό checkpoint κάθε εκπαίδευσης αποθηκεύεται αυτόματα για χρήση στη φάση αξιολόγησης.

2.4.4 Μετρικές Αξιολόγησης

Η αξιολόγηση των μοντέλων πραγματοποιείται στο test set κάθε subject (επαναλήψεις 2 και 5), το οποίο παραμένει αδιαπέραστο καθ' όλη τη διάρκεια της εκπαίδευσης. Χρησιμοποιούνται οι ακόλουθες μετρικές:

- **Accuracy:** Το ποσοστό ορθά ταξινομημένων παραθύρων επί του συνόλου, αναφέρεται τόσο ανά subject όσο και ως μέσος όρος.
- **Macro F1-Score:** Ο αρμονικός μέσος ακρίβειας (precision) και ανάκλησης (recall), υπολογισμένος ανεξάρτητα ανά κλάση και στη συνέχεια μέσος όρος χωρίς στάθμιση, κατάλληλος για αξιολόγηση σε ισορροπημένα datasets πολλών κλάσεων.
- **Confusion Matrix:** Πίνακας σύγχυσης 17×17 ανά subject, που αναδεικνύει συστηματικές συγχύσεις μεταξύ κινησιολογικά παρόμοιων χειρονομιών.

Τα αποτελέσματα συγκρίνονται με τα αντίστοιχα της βιβλιογραφίας αναφοράς [4], η οποία αναφέρει μέση ακρίβεια ~68.98% για raw σήματα και ~68.47% για spectrogram-based προσέγγιση στο NinaPro DB5 με 18 κλάσεις.

Πέραν της ταξινομητικής απόδοσης, αξιολογείται η καταλληλότητα κάθε αρχιτεκτονικής για πραγματικού χρόνου εφαρμογή (real-time feasibility). Το ανώτατο επιτρεπτό χρονικό όριο ορίζεται στα 300ms, βάσει του αντιληπτικού ορίου των Farrell & Weir (2007) όπως αναφέρεται στο [4]. Αφαιρώντας το παράθυρο απόκτησης σήματος των 260ms, απομένουν 40ms για το σύνολο της επεξεργαστικής αλυσίδας. Το budget αυτό κατανέμεται σε δύο στάδια:

- **Προεπεξεργασία:** Για τις αρχιτεκτονικές STFT (SlowFusion, MobileNet), περιλαμβάνει τον υπολογισμό του φάσματος STFT σε 8 κανάλια με παράθυρο Hann, λογαριθμική συμπίεση $\log_{10}$ και μετατροπή σε tensor. Για την TCN, το στάδιο αυτό περιορίζεται σε απλή αναδιάταξη διαστάσεων (transpose).
- **Πρόβλεψη δικτύου:** Ο χρόνος ενός forward pass για ένα μεμονωμένο παράθυρο σε CPU.

Μετράται το p95 της συνολικής καθυστέρησης σε 500 επαναλήψεις σε CPU, ώστε να αποτυπωθεί η συμπεριφορά υπό πρακτικές συνθήκες και όχι μόνο η μέση τιμή. Επιπλέον, υπολογίζεται ο ελάχιστος απαιτούμενος ρυθμός επεξεργασίας σε GFLOP/s που πρέπει να διαθέτει ο επεξεργαστής-στόχος για να ικανοποιηθεί το budget, ορίζεται ως θεωρητικό κατώτατο όριο υπό υπόθεση πλήρους αξιοποίησης υλικού.

3

Αποτελέσματα

Στο κεφάλαιο αυτό παρουσιάζονται τα αποτελέσματα της πειραματικής αξιολόγησης των τεσσάρων αρχιτεκτονικών (SlowFusion 3D-CNN, MobileNetV2, TCN-AoT και TCN-Att) επί του συνόλου δοκιμής του NinaPro DB5 (Exercise B, 17 κλάσεις, 5 subjects). Τα αποτελέσματα οργανώνονται σε τρεις ενότητες: μετρικές ταξινόμησης, ανάλυση πινάκων σύγχυσης και αξιολόγηση καταλληλότητας πραγματικού χρόνου.

3.1 Μετρικές Ταξινόμησης

Ο Πίνακας 1 συγκεντρώνει την ακρίβεια (Accuracy) και το Macro F1-Score κάθε αρχιτεκτονικής για κάθε έναν από τους πέντε συμμετέχοντες, καθώς και τον μέσο όρο επί του συνόλου.



Ακρίβεια (Acc) και Macro F1-Score ανά subject και αρχιτεκτονική

Γραμμή αναφοράς [1]: spectrogram-based ConvNet σε NinaPro DB5 (17 κλάσεις, per-subject). Καλύτερη τιμή ανά γραμμή σε πράσινο.

Subject	[A] SlowFusion		[B] MobileNetV2		[C] TCN-AoT		[C] TCN-Att	
	Acc	F1	Acc	F1	Acc	F1	Acc	F1
s1	0.604	0.615	0.550	0.561	0.626	0.631	0.555	0.563
s2	0.707	0.701	0.610	0.604	0.702	0.700	0.625	0.625
s3	0.596	0.593	0.499	0.500	0.607	0.609	0.499	0.501
s4	0.556	0.558	0.453	0.457	0.582	0.583	0.546	0.547
s5	0.620	0.624	0.551	0.556	0.646	0.650	0.582	0.587

M.O.	0.617	0.618	0.533	0.536	0.632	0.635	0.561	0.565
[1] Αναφ.	~0.6898		,		,		,	


* Το TCN-AoT επιτυγχάνει την υψηλότερη μέση ακρίβεια (63.2%) σε 4 από τους 5 subjects. Το SlowFusion παρουσιάζει την υψηλότερη επίδοση για τον s2 (70.7%).




Το TCN-AoT επιτυγχάνει τη μέγιστη μέση ακρίβεια (63.2%) και μέσο F1 (63.5%), υπερτερώντας σταθερά έναντι των υπολοίπων αρχιτεκτονικών σε 4 από τους 5 subjects. Το SlowFusion ακολουθεί με 61.7% / 61.8%, ενώ το TCN-Att κατατάσσεται τρίτο με 56.1% / 56.5%. Το MobileNetV2 εμφανίζει τη χαμηλότερη συνολική απόδοση (53.3% / 53.6%) παρά τη χρήση προ-εκπαιδευμένων βαρών ImageNet. Αξιοσημείωτη εξαίρεση αποτελεί ο subject s2, όπου το SlowFusion φτάνει σε ακρίβεια 70.7%, εγγύτερα στη γραμμή αναφοράς [1] (~68.98%).

Η σύγκριση TCN-AoT έναντι TCN-Att αποκαλύπτει ότι ο απλός μέσος όρος χρονικής κατανομής (Average-over-Time) υπερέχει σταθερά του attention pooling σε όλους τους subjects. Αυτό υποδηλώνει ότι, για το συγκεκριμένο μέγεθος δεδομένων ανά subject, το attention δεν προσδίδει πρόσθετη πληροφορία και ενδέχεται να οδηγεί σε ελαφρά υπερεκπαίδευση.

3.2 Ανάλυση Πινάκων Σύγχυσης





Η Εικόνα 2 παρουσιάζει τους πίνακες σύγχυσης 17×17 για τον subject s1 και για τις τέσσερις αρχιτεκτονικές. Και στις τέσσερις περιπτώσεις η διαγώνιος είναι κυρίαρχη, επιβεβαιώνοντας τη βασική ικανότητα ταξινόμησης. Στο TCN-AoT παρατηρείται η σαφέστερη διαγώνιος με την πιο περιορισμένη διασπορά εκτός αυτής ($\text{acc}=0.626$), ενώ στο SlowFusion εντοπίζεται παρόμοιο μοτίβο ($\text{acc}=0.604$). Αντίθετα, το MobileNetV2 ($\text{acc}=0.550$) και το TCN-Att ($\text{acc}=0.555$) παρουσιάζουν μεγαλύτερη σύγχυση, κυρίως μεταξύ κινησιολογικά παρόμοιων χειρονομιών δακτύλων (κλάσεις 3-4 και 7-9). Το μοτίβο αυτό παρατηρείται σε όλους τους subjects και υποδηλώνει ότι οι συγκεκριμένες κλάσεις παράγουν φασματικά και χρονικά παρόμοιο EMG σήμα, ανεξαρτήτως αρχιτεκτονικής.

3.3 Αξιολόγηση Καταλληλότητας Πραγματικού Χρόνου

Ο Πίνακας 2 συνοψίζει τα χαρακτηριστικά υπολογιστικής πολυπλοκότητας και τα αποτελέσματα του benchmark πραγματικού χρόνου για κάθε αρχιτεκτονική. Το κριτήριο επιτυχίας ορίζεται ως $\text{total p95 latency} \leq 40 \text{ ms}$, δεδομένου ότι το παράθυρο λήψης δεσμεύει ήδη τα 260 ms από το συνολικό budget των 300 ms.

Πίνακας 2


Αποτελέσματα benchmark πραγματικού χρόνου (CPU inference, single window)



Κριτήριο επιτυχίας: total p95 $\leq$ 40 ms. Το παράθυρο λήψης δεσμεύει ήδη 260 ms από το budget των 300 ms.

Μετρική	[A] SlowFusion	[B] MobileNetV 2	[C] TCN- AoT	[C] TCN- Att
Παράμετροι (σύνολο)	187,473	2,245,649	23,889	24,977
Εκπαιδευσιμες παράμετροι	187,473	2,190,161	23,889	24,977
Μέγεθος μοντέλου	0.8 MB	9.2 MB	0.1 MB	0.1 MB
GFLOPs (ανά inference)	0.0108	0.0489	0.0023	0.0025
Preprocessing μέσος όρος	1.24 ms	1.42 ms	0.01 ms	0.01 ms
Network μέσος όρος	0.66 ms	8.20 ms	1.86 ms	1.90 ms
Total μέσος όρος	1.90 ms	9.62 ms	1.87 ms	1.90 ms

Total p95	3.02 ms	11.33 ms	3.05 ms	3.13 ms
Min GFLOP/s για budget 40 ms	0.270	1.224	0.059	0.061
RT έλεγχος ($p_{95} \leq 40$ ms)	✓ PASS	✓ PASS	✓ PASS	✓ PASS

* Preprocessing TCN: απλό numpy transpose $(52,8) \rightarrow (1,8,52)$, χωρίς STFT.
Preprocessing SlowFusion/MobileNetV2: STFT 8 καναλιών + log1p + reshape (~ 1.4 ms).





Και οι τέσσερις αρχιτεκτονικές πληρούν το κριτήριο πραγματικού χρόνου με σημαντικό περιθώριο. Ωστόσο, υπάρχουν σημαντικές διαφορές στο αποτύπωμα και στη σύνθεση της καθυστέρησης. Το TCN-AoT και το TCN-Att εκτελούν το πλήρες pipeline σε μέσο χρόνο 1.87 ms και 1.90 ms αντίστοιχα

(p95 ≈ 3.1 ms), με αμελητέο preprocessing (0.01 ms) καθώς δεν απαιτούν STFT, χρησιμοποιούν απευθείας το ακατέργαστο EMG μέσω απλού numpy transpose. Το SlowFusion εκτελείται εξίσου γρήγορα (μέσος χρόνος 1.90 ms, p95 3.02 ms), αλλά προσθέτει ~ 1.24 ms preprocessing για την εξαγωγή STFT φασματογραφημάτων. Το MobileNetV2 παρουσιάζει τη μεγαλύτερη καθυστέρηση (μέσος χρόνος 9.62 ms, p95 11.33 ms), κυρίως λόγω της αύξησης της χωρικής ανάλυσης σε 64×64 pixels κατά το preprocessing της εισόδου του.

Από πλευράς πολυπλοκότητας, τα TCN αποδεικνύονται εξαιρετικά compact: $\sim 24k$ παράμετροι και 0.1 MB σε δίσκο, έναντι 187k παραμέτρων (0.8 MB) του SlowFusion και 2.24M παραμέτρων (9.2 MB) του MobileNetV2. Ο συνδυασμός υψηλότερης ακρίβειας, ελαχίστων παραμέτρων, μηδενικού preprocessing κόστους και χαμηλότερων GFLOPs καθιστά το TCN-AoT ως την καταλληλότερη αρχιτεκτονική για ενσωματωμένα συστήματα HMI πραγματικού χρόνου.

4

Επίλογος-Συμπεράσματα

4.1 Σύνοψη και συμπεράσματα

Σκοπός της παρούσας εργασίας ήταν η συγκριτική αξιολόγηση τεσσάρων αρχιτεκτονικών βαθιάς μάθησης για την αναγνώριση χειρονομιών από σήματα επιφανειακού ηλεκτρομυογραφήματος (sEMG), στο πλαίσιο εφαρμογών ελέγχου νευροπροσθετικών συσκευών άνω άκρων. Συγκεκριμένα, εξετάστηκαν δύο προσεγγίσεις που βασίζονται στη μετατροπή του sEMG σε φασματογραφήματα μέσω STFT, το SlowFusion 3D-CNN και το MobileNetV2, καθώς και δύο χρονοακολουθιακές προσεγγίσεις, το TCN-AoT και το TCN-Att, οι οποίες επεξεργάζονται απευθείας το ακατέργαστο σήμα. Η αξιολόγηση δεν περιορίστηκε μόνο στην ακρίβεια ταξινόμησης, αλλά έλαβε υπόψη και την καταλληλότητα των μοντέλων για χρήση σε πραγματικό χρόνο, καθώς σε εφαρμογές προσθετικής απαιτούνται μικρή καθυστέρηση, χαμηλό υπολογιστικό κόστος και περιορισμένο αποτύπωμα μνήμης.

Από τα πειραματικά αποτελέσματα προκύπτει ότι η καλύτερη συνολική επίδοση επιτεύχθηκε από το TCN-AoT, με μέση ακρίβεια 63.2% και μέσο Macro F1-Score 63.5%. Δεύτερο ακολούθησε το SlowFusion, με μέση ακρίβεια 61.7% και F1-Score 61.8%, ενώ το TCN-Att εμφάνισε χαμηλότερη επίδοση από τα δύο παραπάνω μοντέλα, με μέση ακρίβεια 56.1% και Macro F1-Score 56.5%. Το MobileNetV2 παρουσίασε τη χαμηλότερη συνολική επίδοση, με μέση ακρίβεια 53.3%, παρότι αξιοποιεί transfer learning από το ImageNet.

Η υπεροχή του TCN-AoT δείχνει ότι η απευθείας χρονική επεξεργασία του ακατέργαστου sEMG μπορεί να είναι ιδιαίτερα αποτελεσματική, χωρίς να είναι απαραίτητη σε κάθε περίπτωση η μετατροπή του σήματος σε φασματογράφημα. Παρόλο που τα STFT spectrograms παρέχουν χρήσιμη χρονοσυχνотική πληροφορία, στην παρούσα υλοποίηση το TCN-AoT φαίνεται να αξιοποίησε καλύτερα τη χρονική δομή του σήματος. Μία πιθανή εξήγηση είναι ότι η συχνότητα δειγματοληψίας των 200 Hz της Myo armband περιορίζει ήδη τη διαθέσιμη φασματική πληροφορία, ενώ η

συμπίεση των 52 χρονικών δειγμάτων σε λίγα χρονικά bins μέσω STFT μπορεί να οδηγεί σε απώλεια μέρους της πληροφορίας.

Το SlowFusion παρουσίασε επίσης αρκετά καλή συμπεριφορά, με απόδοση κοντά στο TCN-AoT. Μάλιστα, σε έναν από τους συμμετέχοντες πέτυχε την καλύτερη επιμέρους επίδοση της εργασίας, με ακρίβεια κοντά στο 71%. Αυτό δείχνει ότι η αναπαράσταση μέσω STFT παραμένει αξιόλογη, ειδικά όταν η αρχιτεκτονική έχει σχεδιαστεί ώστε να συγχωνεύει σταδιακά τη χρονική πληροφορία. Ωστόσο, ο ελαφρώς καλύτερος μέσος όρος του TCN-AoT δείχνει ότι, στη συγκεκριμένη πειραματική συνθήκη, η πιο άμεσα προσαρμοσμένη στη χρονική φύση του προβλήματος προσέγγιση απέδωσε καλύτερα.

Το MobileNetV2 δεν απέδωσε όσο αναμενόταν, παρότι αξιοποιεί transfer learning από το ImageNet. Η βασική αιτία φαίνεται να είναι το σημαντικό domain gap μεταξύ των φυσικών εικόνων RGB και των φασματογραφημάτων sEMG. Τα χαρακτηριστικά που έχει μάθει το δίκτυο από φυσικές εικόνες, όπως ακμές, σχήματα και υφές, δεν μεταφέρονται απαραίτητα αποδοτικά σε βιοσήματα. Επιπλέον, η αναδιαμόρφωση των δεδομένων σε εικόνες 64×64 προσθέτει επιπλέον επεξεργασία χωρίς να αυξάνει απαραίτητα την πραγματική πληροφορία που έχει στη διάθεσή του το μοντέλο.

Ιδιαίτερο ενδιαφέρον παρουσιάζει η σύγκριση μεταξύ TCN-AoT και TCN-Att. Αν και ο μηχανισμός attention θεωρητικά επιτρέπει στο μοντέλο να δίνει μεγαλύτερη βαρύτητα στα πιο πληροφοριακά χρονικά σημεία, στην παρούσα εργασία το TCN-Att είχε χαμηλότερη απόδοση από το TCN-AoT, αν και παρέμεινε πάνω από το MobileNetV2. Η διαφορά αυτή πιθανότατα σχετίζεται με την απουσία επαύξησης δεδομένων, το μικρό μέγεθος του χρονικού παραθύρου και τη χαμηλότερη ποιότητα του σήματος της Myo armband σε σχέση με πιο εξειδικευμένους αισθητήρες. Επομένως, ο attention μηχανισμός φαίνεται ότι χρειάζεται περισσότερα δεδομένα και πλουσιότερο χρονικό πλαίσιο για να αξιοποιηθεί αποτελεσματικά.

Όσον αφορά την καταλληλότητα για χρήση σε πραγματικό χρόνο, και οι τέσσερις αρχιτεκτονικές ικανοποίησαν το κριτήριο των 40 ms ανά παράθυρο, το οποίο προκύπτει από το συνολικό όριο των 300 ms, αφαιρώντας τα 260 ms που δεσμεύονται από το παράθυρο λήψης του σήματος. Τα TCN-AoT και TCN-Att είχαν p95 latency περίπου 3 ms και πολύ μικρό μέγεθος μοντέλου, περίπου 0.1 MB, ενώ δεν απαιτούν STFT preprocessing. Το SlowFusion εμφάνισε επίσης πολύ χαμηλή καθυστέρηση, αν και χρειάζεται επιπλέον το στάδιο εξαγωγής φασματογραφήματος. Το MobileNetV2

ήταν το βαρύτερο μοντέλο, με μέγεθος 9.2 MB και p95 latency 11.33 ms, παραμένοντας όμως εντός των ορίων πραγματικού χρόνου.

Συνολικά, το TCN-AoT προσφέρει την καλύτερη ισορροπία μεταξύ ακρίβειας, ταχύτητας και αποτυπώματος μνήμης. Για τον λόγο αυτό αναδεικνύεται ως η πιο κατάλληλη επιλογή στο πλαίσιο της παρούσας μελέτης για πιθανή ενσωμάτωση σε πραγματική προσθετική συσκευή. Παράλληλα, τα αποτελέσματα δείχνουν ότι οι απόλυτες τιμές ακρίβειας παραμένουν μέτριες, γεγονός αναμενόμενο λόγω της φύσης του sEMG. Το σήμα επηρεάζεται έντονα από θόρυβο, μεταβλητότητα μεταξύ χρηστών, μικρές αλλαγές στην εκτέλεση των χειρονομιών, μετατόπιση των ηλεκτροδίων και περιορισμούς της συσκευής καταγραφής. Επομένως, τα αποτελέσματα πρέπει να ερμηνεύονται όχι μόνο ως ποσοστά ταξινόμησης, αλλά κυρίως ως ένδειξη της πρακτικότητας κάθε αρχιτεκτονικής για εφαρμογές πραγματικού χρόνου.

Τέλος, πρέπει να αναφερθούν ορισμένοι περιορισμοί της εργασίας. Η αξιολόγηση πραγματοποιήθηκε σε intra-subject πλαίσιο, δηλαδή ξεχωριστά για κάθε χρήστη, οπότε δεν εξετάστηκε η γενίκευση σε νέους χρήστες. Επίσης, η κλάση ηρεμίας δεν συμπεριλήφθηκε στην εκπαίδευση, κάτι που περιορίζει την άμεση εφαρμογή του συστήματος σε streaming περιβάλλον. Επιπλέον, δεν χρησιμοποιήθηκαν τεχνικές επαύξησης δεδομένων, παρότι η βιβλιογραφία δείχνει ότι μπορούν να βελτιώσουν σημαντικά τη γενίκευση των μοντέλων. Παρά τους περιορισμούς αυτούς, η συγκριτική κατάταξη των αρχιτεκτονικών είναι αρκετά καθαρή και επιτρέπει την εξαγωγή χρήσιμων συμπερασμάτων.

4.2 Μελλοντικές επεκτάσεις

Μια πρώτη σημαντική επέκταση της παρούσας εργασίας θα ήταν η εφαρμογή τεχνικών επαύξησης δεδομένων, όπως time-warping, magnitude-warping, jittering και προσθήκη Gaussian noise. Η χρήση τέτοιων τεχνικών θα μπορούσε να βελτιώσει τη γενίκευση των μοντέλων και πιθανώς να μειώσει τη διαφορά απόδοσης που παρατηρήθηκε σε σχέση με τη βιβλιογραφία. Επιπλέον, θα μπορούσε να βοηθήσει ιδιαίτερα το TCN-Att, καθώς ο μηχανισμός attention χρειάζεται μεγαλύτερο όγκο δεδομένων για να εκπαιδευτεί αξιόπιστα.

Μια δεύτερη κατεύθυνση αφορά την αξιολόγηση των μοντέλων σε μεγαλύτερο αριθμό συμμετεχόντων και σε επιπλέον σύνολα δεδομένων, όπως τα υπόλοιπα NinaPro DB ή

το GRABMyo. Με αυτόν τον τρόπο θα μπορούσε να εξεταστεί πιο ολοκληρωμένα η ικανότητα γενίκευσης των αρχιτεκτονικών σε διαφορετικούς χρήστες, διαφορετικές συσκευές καταγραφής και διαφορετικές συνθήκες μέτρησης. Στο ίδιο πλαίσιο, ενδιαφέρον παρουσιάζουν και τεχνικές cross-subject transfer learning και domain adaptation, οι οποίες θα μπορούσαν να μειώσουν την ανάγκη για εξατομικευμένη εκπαίδευση κάθε νέου χρήστη.

Επιπλέον, θα είχε ενδιαφέρον να διερευνηθούν διαφορετικά μεγέθη χρονικού παραθύρου. Στην παρούσα εργασία χρησιμοποιήθηκαν παράθυρα διάρκειας 260 ms, ώστε να υπάρχει ισορροπία μεταξύ διαθέσιμης πληροφορίας και καθυστέρησης. Μικρότερα παράθυρα θα μπορούσαν να μειώσουν περαιτέρω τον χρόνο απόκρισης, ενώ μεγαλύτερα ίσως βελτιώναν την ακρίβεια ταξινόμησης. Η διερεύνηση αυτού του συμβιβασμού είναι ιδιαίτερα σημαντική σε εφαρμογές προσθετικής, όπου η αίσθηση άμεσης απόκρισης επηρεάζει την αποδοχή της συσκευής από τον χρήστη.

Σημαντική μελλοντική βελτίωση θα ήταν επίσης η ενσωμάτωση της κλάσης ηρεμίας στο σύνολο εκπαίδευσης, ώστε το πρόβλημα να μετατραπεί σε ταξινόμηση 18 κλάσεων. Σε ένα πραγματικό streaming περιβάλλον, το σύστημα δεν πρέπει μόνο να αναγνωρίζει ποια χειρονομία εκτελείται, αλλά και πότε δεν υπάρχει πρόθεση κίνησης. Η δυνατότητα αυτή είναι απαραίτητη για την ασφαλή και φυσική λειτουργία μιας προσθετικής συσκευής.

Μελλοντική εργασία θα μπορούσε ακόμη να εστιάσει στη βελτιστοποίηση των μοντέλων για πραγματικό embedded hardware. Παρότι τα benchmarks έδειξαν ότι όλα τα μοντέλα τηρούν τα χρονικά όρια, η υλοποίηση σε μικροελεγκτές ή φορητές συσκευές απαιτεί επιπλέον τεχνικές, όπως quantization, pruning και hardware-aware optimization. Ειδικά το TCN-AoT, λόγω του μικρού μεγέθους και της χαμηλής υπολογιστικής απαίτησής του, φαίνεται να αποτελεί πολύ καλό υποψήφιο για τέτοιες βελτιστοποιήσεις.

Τέλος, μια πιο εφαρμοσμένη επέκταση θα ήταν η ενσωμάτωση του συστήματος σε ένα πρωτότυπο περιβάλλον ελέγχου προσθετικού χεριού. Η παρούσα αξιολόγηση έγινε offline, πάνω σε καταγεγραμμένα δεδομένα. Σε πραγματική χρήση, όμως, ο χρήστης αλληλεπιδρά συνεχώς με το σύστημα και προσαρμόζει τη μυϊκή του δραστηριότητα ανάλογα με την απόκριση της συσκευής. Για τον λόγο αυτό, η τελική αξιολόγηση θα πρέπει να περιλαμβάνει και online πειράματα, όπου θα εξετάζονται όχι μόνο η ακρίβεια

ταξινόμησης, αλλά και η ευχρηστία, η σταθερότητα, η άνεση και η εμπιστοσύνη του χρήστη απέναντι στο σύστημα.

Συμπερασματικά, η εργασία δείχνει ότι η χρήση βαθιάς μάθησης για την αναγνώριση χειρονομιών από sEMG αποτελεί μια ρεαλιστική και πολλά υποσχόμενη προσέγγιση για τον έλεγχο νευροπροσθετικών συσκευών. Παρά τις δυσκολίες που παρουσιάζει το σήμα, τα ελαφριά χρονοακολουθιακά συνελικτικά δίκτυα (και ιδιαίτερα το TCN-AoT) μπορούν να προσφέρουν ικανοποιητική απόδοση με πολύ μικρό υπολογιστικό κόστος. Με περαιτέρω βελτιώσεις στα δεδομένα, στη γενίκευση και στην embedded υλοποίηση, τέτοιες προσεγγίσεις μπορούν να συμβάλουν στην ανάπτυξη πιο φυσικών και άμεσων διεπαφών ανθρώπου-μηχανής στο πεδίο της προσθετικής.

5

Βιβλιογραφία

- [1] M. Zanghieri, "sEMG-based Hand Gesture Recognition with Deep Learning," Master's thesis, University of Bologna, Bologna, Italy, 2019.
- [2] W. Geng, Y. Du, W. Jin, W. Wei, Y. Hu, and J. Li, "Gesture recognition by instantaneous surface EMG images," *Scientific Reports*, vol. 6, p. 36571, 2016.
- [3] M. Atzori, A. Gijsberts, C. Castellini, B. Caputo, A.-G. Mittaz Hager, S. Elsig, G. Giatsidis, F. Bassetto, and H. Müller, "Electromyography data for non-invasive naturally-controlled robotic hand prostheses," *Scientific Data*, vol. 1, p. 140053, 2014.
- [4] U. Côté-Allard, C. L. Fall, A. Drouin, A. Campeau-Lecours, C. Gosselin, K. Glette, F. Laviolette, and B. Gosselin, "Deep Learning for Electromyographic Hand Gesture Signal Classification Using Transfer Learning," *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 27, no. 4, pp. 760-771, 2019.
- [5] P. Tsinganos, B. Cornelis, J. Cornelis, B. Jansen, and A. Skodras, "Improved Gesture Recognition Based on sEMG Signals and TCN," in Proc. IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), Brighton, UK, May 2019, pp. 1169–1173, doi: 10.1109/ICASSP.2019.8683239.